

CAGE: Query Control 在三维功能区域定位中的 传播、衰减与因果定位

中文题目：CAGE——面向语言引导三维功能部位定位的查询控制传播机制分析

一句话概括：不把 CAGE 当新方法，而把它当作”测量装置”——先用同一几何下的有效 query pair 证明 point-level mask switching failure，再沿 query → 文本编码 → 跨模态融合 → 点表示 → 解码器这条链路定位 query control 在哪里丢失，最后用双向因果干预判断该位置是否真正控制空间决策；只有因果定位成立，才允许方法从机制中产生。

版本：final idea 版，2026-09-20。本文给出确定的研究对象和分阶段验证路线；尚无本方法实验结果，正式方法保持空白。

1 1. 引言

1.1 1.1 背景

语言引导三维功能部位定位的任务是：给定物体点云和任务描述，输出与当前功能相关的逐点热图。同一件工具，在”握持””切割””敲击”等不同任务下，应当指向不同的功能区域。因此模型不仅要知道物体是什么、前景在哪里，还必须把 query 里的功能意图传递到正确的点级空间表示上。

这一任务经历了几步推进：LASO / PointRefer 引入自然语言，用多尺度文本-点云融合和 question-conditioned decoder 建立起点；GEAL 用多视图迁移和粒度自适应融合提升泛化；GLANCE 用中间层跨模态连接和几何先验改善未见类别；CMAT 把瓶颈归到三维编码器的语义表征能力，用二维语义先验学习细粒度边界。这些工作都用最终分割指标证明”更准了”，但都没有直接回答一个问题：query 的变化在模型内部是否真的持续影响与目标区域相关的点表示。

1.2 1.2 现有方法留下的问题

上一版方案把问题写成”全局多视图压缩细小区域，所以加局部重渲染、全局语境和选择性蒸馏”。核验全文和代码后，这条主张被直接覆盖：PointRefer 已做多尺度，GEAL 已做粒度自适应融合，GLANCE 已做全局语义加局部几何，CMAT 已从编码器语义容量解释细粒度边界。crop/zoom、cross-attention、选择性蒸馏即使有效，也很难单独构成结构性新问题。

更关键的是，现有工作的评测方式本身有盲区：标准 object-affordance 配对协议奖励”正确 mask”，却无法区分这个 mask 是由当前 query 决定的，还是由对象类别、几何和 object-affordance 共现先验猜中的。一个模型可能在标准 benchmark 上拿高分，却分不清”抓把手”和”抓刀刃”——这对抓取、巡检这类任务意味着选错功能区域就是事故。

由此形成本文的核心问题：

当 query 改变而几何保持不变时，模型内部的 query-dependent 变化能否传递到相关点并驱动正确的 mask 切换？如果不能，控制能力在哪个计算环节丢失？

1.3 1.3 核心思路

本文不再把 CAGE 当作新方法，而把它当作测量装置：先用同一几何、不同有效功能 mask 的天然对照证明 failure 存在，再沿传播链路定位衰减区间，最后用双向干预判断该位置是否因果控制空间决策。只有因果定位成立，才允许方法从具体机制中产生，而不是预先缝一个通用模块。

2 2. CAGE 方法（测量装置，非主方法）

2.1 2.1 总体定位

研究链路固定为：

query $q \rightarrow$ 文本编码 $E_q \rightarrow$ 跨模态融合 $Fusion(P, E_q) \rightarrow$ 点表示 $Z_point \rightarrow$ 解码器 $Decoder \rightarrow$ 逐点 mask

CAGE 只提供定位故障所需的受控材料和测量工具，不承担论文核心创新，也不能单独支持“发现机制”的主张。它像一个显微镜和一把手术刀：显微镜看 query control 在哪一层衰减，手术刀做定点干预验证因果。

2.2 2.2 受控配对

- **CAGE-Pair:** 同一 shape、两个不同有效 affordance、mask 低重叠的配对，用于验证 mask switching。
- **CAGE-Para:** 同一 shape、同一 affordance、不同问题改写，用于验证语义等价不变性。

配对由现有标注确定性生成；语义关系（互斥 / 共享区域 / 可并存 / 蕴含层级 / 歧义）由双人盲审冻结，IoU 只做几何过滤、不替代语义判定。测试 pair 不参与任何超参数选择。

2.3 2.3 行为诊断

对每个合法 pair 跑 $(P, q_a) \rightarrow p_a$ 和 $(P, q_b) \rightarrow p_b$ ，检查从 q_a 到 q_b 时预测是否朝 y_b 方向切换。null、shuffle、错误 object 只做压力测试，不进主要存在性判定。主要量 $T(p; y_a, y_b) = S(p, y_b) - S(p, y_a)$ ，同时报告标准 aIoU/AUC/SIM/MAE，避免新指标脱离原任务。

2.4 2.4 表示定位

沿链路记录各层表示，回答四个问题：差异是否存在、差异是否衰减、差异是否落在 $y_a \text{ XOR } y_b$ 的目标区域、差异是否可被 readout 读出。注意 readout 成功只说明信息存在，不说明模型实际使

用。任何单一距离（cosine、CKA、probe accuracy）都不能直接定位根因，必须检查结论对度量选择的稳定性。

2.5 2.5 因果干预

对 candidate locus 做双向干预：**restoration**（把 target-query 的 query-dependent 分量 patch 到 source-query run，看 mask 是否朝正确方向切换）和 **destruction**（对原本切换正确的样本破坏该分量，看切换是否受损）。必要控制：norm-matched 随机方向、paraphrase 差异、非候选层同强度、geometry 等强度扰动。只有 restoration 有效但 destruction 无效时，最多说明该路径具有替代性，不足以声称必要机制。

3 3. 拟贡献

本研究只卖一个贡献：在 **dense language-guided 3D affordance grounding** 中，用同一几何、不同有效功能 mask 的天然对照，因果定位 query control 在哪一步失去对点级空间决策的控制，并给出该环节的最小机制修复。

其三个子点（一个贡献的三个子点，不是三个独立贡献）：

1. **行为存在性证据**：受控 pair 上存在 query-insensitive prediction，并排除语义歧义、mask 重叠、尺度和改写噪声。
2. **因果定位装置**：CAGE 的双向定点干预定位候选环节，并证明其因果作用。
3. **机制结论与最小修复**：被定位机制跨至少两个架构复现，且最小结构修改（非通用 loss）能恢复 query control。

如果因果干预只证明”相关”而非”因果”，则贡献收缩为前两个子点，形态降为诊断评测，不再声称机制。无论哪种结果，贡献都不空缺。

4 4. Baseline 与开源代码

模型或组合	用途	开源情况
PointRefer / LASO	最早的文字-点融合起点，首要被解释对象	官方代码与数据
GEAL	多粒度融合与 2D-3D 一致性的主基线	官方代码、LASO/PIAD 权重与评测入口
GLANCE	中间层跨模态连接的强邻居	论文已核；代码稳定性待确认
CMAT	2026 强基线，直接暴露 prompt 与 fused point features	官方代码；权重与单卡成本待审计

机制定位至少需要两个内部结构不同的可复现模型，优先 PointRefer 和 GEAL。黑盒输出只能参加行为诊断，不能承担表示定位与因果干预的结论。CMAT/GLANCE 只在官方权重与 hook 入口审计通过后加入，用于跨模型复现；审计不过不影响主线，只把结论限定在已验证的架构上。

5 5. 数据集

数据集	规模与特点	建议用途
LASO	19,751 个点云-问题对, 8,434 个形状, 23 类, 17 种功能	主数据; 同 shape 多 affordance 配对、主要诊断
PIAD	7,012 个点云实例	只有在能建立等价语言与同对象多 affordance 映射时作外部验证; 不复用 LASO 文本后宣称独立语言泛化

功能标签是软热图, 不改写成精确抓取接触标签。LASO 的 seen/unseen 划分按被比较工作的协议固定, 避免同 shape 泄漏。

6 6. 分阶段实验路线

6.1 阶段 A: 证明现象存在 (不训练)

先做数据审计: 按 shape 聚合标注, 统计每个 shape 的 affordance 数量、mask 两两 IoU 和前景点比例。**可行性门槛:** test 中至少 30% 的 shape 能形成”同 shape、 ≥ 2 个有效 affordance、 $\text{IoU} < 0.5$ ”的配对, 且总配对数不少于 300; 否则 LASO 不能作为反事实主数据, 本题退回。

数据够用后, 用官方预训练 PointRefer 和 GEAL 跑 query swap 诊断, 回答: mask switching 是否真实存在? 是否不能被 mask 重叠、尺度、类别或改写噪声解释? 阶段 A 要回答的问题只有一个——”failure 到底存不存在”。

6.2 阶段 B: 定位衰减区间 (不训练)

沿链路记录表示, 回答差异在哪里衰减、是否落在目标区域。此阶段只输出 candidate locus, 不宣称因果。

6.3 阶段 C: 因果干预

对 candidate locus 做 restoration 和 destruction, 判断它是决定性机制、还是相关痕迹。这是机制主张的最低门槛。

6.4 阶段 D: 方法 (仅在 C 通过后)

方法从已验证机制中产生: 修改位置与 locus 一致, 计算作用对应机制而非通用 loss, 先恢复内部 signal 再报 mask 指标, 并用最小非机制修补和算力匹配对照排除”只是容量更大”。

7 7. 算力与周期

阶段 A-C 全部使用官方预训练权重做推理与干预，不训练新模型，单张 RTX 4090 足够。只有阶段 D 才涉及训练，且训练预算在 C 通过后才评估。首轮不下载无关模态，不启动完整训练。真实训练时间以 4090 短跑实测为准，不提前承诺固定天数。

8 8. 立项判断

这是一个科学上限明显高于“诊断 + 指标 + loss”的方向，但也明显更难：它已经具备可证伪的机制发现流程，却还没有任何已验证的 failure、candidate locus 或因果机制。

最关键的三项成立条件是：

1. 数据能构造足量、语义有效、低重叠的同一形状多功能配对；
2. 至少两个结构不同的 baseline 暴露一致的 switching failure，且不能被几何、尺度和改写噪声解释；
3. 因果干预能定位一个决定性机制，且最小结构修改能恢复 query control。

若第一项不成立，本题停止；若前两项成立而第三项不成立，收缩为诊断评测论文；若第一项也不成立，不投入任何后续。

最终研究主线：先证明 query control 确实丢失，再定位它在哪丢失、因何丢失，最后只修复那个被因果验证的环节——而不是堆更多通用模块。