


CAGE

Query Control 在三维功能区域定位中的传播、衰减与因果定位

研究方案报告 | 导师讨论初稿 | v0.1



研究对象

CAGE 是 measurement apparatus, 不是 method。

先确认 behaviour, 再定位 representation, 最后做 causal intervention。

D2 通过前, 正式方法保持空白。

一句话概括

本研究不再把 CAGE 当作新方法，而把它作为 measurement apparatus：先用同一几何下的有效 query pair 证明 point-level mask switching failure，再沿 $q \rightarrow E_q \rightarrow \text{Fusion} \rightarrow Z_{\text{point}} \rightarrow \text{Decoder} \rightarrow \text{Mask}$ 定位 query control 的候选衰减区间，最后通过 activation patching、bypass、injection 和 ablation 的双向干预判断该位置是否真正控制最终空间决策。只有因果定位成立后，才允许方法从具体机制中产生。

1. 研究背景与问题变化

1.1 任务背景

Language-guided 3D affordance grounding 接收物体点云和任务问题，输出与当前功能相关的逐点 mask。同一把工具可能因“握持”“切割”“敲击”等有效 query 指向不同功能区域，因此模型不仅要识别物体和前景，还必须把 query 中的功能意图传递到正确的点级空间表示。

LASO/PointRefer 已通过多尺度 text-point fusion、question-conditioned affordance query 和动态 mask kernel 建立任务起点。GEAL 进一步引入多粒度融合和 2D-3D 一致性；GLANCE 使用中间层 cross-modal connector 和几何 query；CMAT/LAS 通过 2D semantic affinity pretraining 与 co-attentional fusion 提升 point representation。现有工作主要用最终分割指标证明模型更准，却没有直接回答：query change 在内部是否持续影响与目标区域相关的 point representation。

1.2 旧主线为什么停止

上一版把问题写成 instruction faithfulness，并以 controlled pairs、sensitivity metrics 和 paired loss 形成闭环。这个闭环可以完成一篇评测或增量优化工作，但诊断、指标和通用 loss 都是研究工具，不是表示机制贡献。它最多回答“模型是否随 query 改变”，不能回答“query control 在何处、因何丢失”。

因此研究对象改为：

为什么 language-guided 3D affordance model 在 query 改变时，内部表示没有发生足以驱动 point-level prediction 改变的变化？

1.3 新的主线

待检验现象：同一几何下，不同有效 query 有时可能无法驱动正确的 point-level mask switching。

根问题：query information 沿下列链路传播时，在哪里失去对空间决策的控制？

$q \rightarrow E_q \rightarrow \text{Fusion}(P, E_q) \rightarrow Z_{\text{point}} \rightarrow \text{Decoder} \rightarrow \text{Mask}$

核心证据要求：不能只观察某层表示“变得相似”；必须定点恢复或破坏该层的 query-dependent component，并观察最终 mask switching 是否相应恢复或受损。

2. 工作定位与论文边界

2.1 CAGE 的定位

CAGE 只保留三类能力：

- 行为 probe：valid swap 为主，null/shuffle/wrong-object 为压力测试；
- controlled evaluation：CAGE-Pair 与 CAGE-Para；
- sensitivity measurement：测量输出与中间表示对 query change 的响应。

CAGE 是显微镜和手术刀，不是论文主方法。Counterfactual Swap Margin、representation distance、linear probe 等都是仪器读数，不能单独形成机制主张。

2.2 当前不包含正式方法

本报告取消预设方法章节。Routing、binding、conditional modulation 和 point-query interaction 只是潜在设计空间；D2 未证明具体机制以前，不命名、不实现、不声称任何一个答案是。

Paired loss 进一步降级为 non-mechanistic intervention control：如果普通 paired supervision 已同时恢复内部 query signal、空间对齐和 mask switching，failure 更可能来自监督不足，不需要提出新的 representation mechanism。

3. 最近邻机制工作查重

3.1 本轮检索范围

本轮针对四类最近邻进行定向查重：

- 1
- language-guided 3D affordance segmentation 的 text encoder、fusion、point feature 和 decoder 结构；
- 2
- controlled/counterfactual affordance evaluation；
- 3
- multimodal representation dominance、cross-modal influence 和 input ablation；
- 4
- activation patching、path patching 与 VLM causal tracing。

来源限于 CVF/ACL/NeurIPS/PMLR/OpenReview/arXiv 正文和官方 GitHub。该检索用于建立初稿边界，不宣称已经穷尽所有 2026 年工作；进入 baseline 前仍需补齐 Top-10 最近邻的全文主张表。

3.2 最近邻矩阵

工作	直接相关机制	对本题的威胁	当前边界
LASO / PointRefer, CVPR 2024	三次语言注入、question-conditioned decoder、动态 mask kernel	高	是首要被解释对象，但未做同几何 query pair 的层级因果定位
GEAL, CVPR 2025	多层 GAFM、feature propagation、text decoder 与 point-wise map	高	融合链更完整，仍以性能和跨模态一致性为主
GLANCE, ICCV 2025	intermediate connector 将 text/3D 中间层概念注入 point embedding	高	已占据“中间层连接改善表示”；不能把 connector 本身当新贡献
CMAT/LAS, CVPR 2026	prompt/point projection、统一序列 co-attention、dense head	高	代码直接暴露 prompt 与 fused point features，是强机制 baseline；未见 query-control causal localization
GroundBench, arXiv 2026	factorized information conditions、same-image counterfactual re-ask	极高	已占据 affordance counterfactual diagnosis；本题不能以行为评测作为核心新颖性
Palit et al., ICCV Workshop 2023	将 causal tracing 适配到 BLIP，定位后层表示的因果相关性	高	已占据“把 causal tracing 用到 VLM”；本题必须依靠 point-level spatial control 和 3D 架构机制
Same Task, Different Circuits, NeurIPS 2025	circuit localization 与 later-to-earlier back-patching，恢复部分跨模态性能差距	极高	与“信息到得太晚、无法影响后续位置”高度相似；不能泛称首次研究 multimodal routing failure
Vision-Default, Prior-Override, arXiv 2026	residual/head/MLP activation patching，区分 routing heads 与 writing heads	极高	已有跨模型 component-level causal mechanism 范式；我们的贡献必须是 dense 3D query-to-point 机制而非 patching 工具
Dual-Pathway Circuits, arXiv 2026	五个 VLM 的 activation patching、路径分析与定点 suppression	高	证明“行为 -> 路径 -> 干预”叙事已成熟；本题需避免照搬到新任务

工作	直接相关机制	对本题的威胁	当前边界
Beyond Cross-Modal Alignment, ACL Findings 2026	Modality Dominance Score 与 training-free feature editing	中高	已占据 modality dominance 测量; 不能把新的 sensitivity scalar 当主贡献
Frank et al., EMNLP 2021	cross-modal input ablation, 发现视觉与文本影响不对称	中	null/ablation 只能作为行为 probe, 不能支持机制结论
Zhang & Nanda, ICLR 2024	系统分析 activation patching 的 metric 与 corruption 选择	方法边界	提醒 patching 结论对度量和 corruption 敏感, 协议必须多控制并预注册

3.3 查重后的真实空间

这条赛道不是空白：行为反事实、模态 dominance、activation patching、路径定位和 representation editing 都已 有直接先例。因此，下列主张均不能作为本研究贡献：

- 首次用 counterfactual prompt 测模型是否使用语言；
- 首次分析 multimodal information flow；
- 首次把 activation patching 用到 vision-language model；
- 提出一个新的 query sensitivity metric；
- 发现多模态模型存在某种 modality dominance。

当前仍可能存活的窄空间是：

在 dense language-guided 3D affordance grounding 中，利用同一几何、不同有效 point mask 的天然对照，因果定位 query-dependent global state 无法路由到相关 point representation 的具体计算环节。

这个差异是否足够形成论文尚未确认。尤其是 NeurIPS 2025 的 back-patching 工作已经提出“表示对齐发生得太晚，无法影响后续位置”，与 H3 的抽象叙事很接近。必须证明 point-level spatial selectivity、架构特定计算路径和 affordance mask switching 带来不可替代的新问题，而不是把同一方法迁移到 3D。

4. 四个竞争性机制假设

H1 - Query collapse

不同有效 query 经 text encoder 后已经过于相似，后端接收不到足够的条件差异。

候选观察： $E(q_a) \sim E(q_b)$ ，且不同有效 query 的差异没有显著高于 paraphrase/noise floor。

H2 - Fusion attenuation

Text representation 可区分，但经过 cross-modal fusion 后，被 geometry/object representation 淹没。

候选观察： $E(q_a) \neq E(q_b)$ ，但 fusion 后 query sensitivity 显著降低。

H3 - Point-level conditioning failure

Global multimodal state 随 query 改变，但该变化没有传递到与两个 GT masks 差异相关的 point/token。

候选观察：global state 可读出 affordance 变化；pointwise representation delta 却无法定位 $y_a \text{ XOR } y_b$ 区域。

这是当前优先验证假设，但不是默认结论。

H4 - Decoder dominance / geometry shortcut

Point representation 已含空间对齐的 query difference，最终 decoder 却主要读取 geometry foreground prior 或 object-specific affordance prior，使 masks 再次趋同。

候选观察：Z_point(P,q_a) 与 Z_point(P,q_b) 在目标差异区域有稳定变化，但 pre-mask/logit 或最终 mask 的 targeted switching 不足。

5. 总体证据阶梯



证据层	允许表述	禁止越界
E0 行为	受控 pair 上存在 switching failure	不能定位内部根因
E1 表示	相邻阶段出现 sensitivity drop，得到 candidate locus	不能称 causal mechanism
E2 干预	restoration/destruction 改变 targeted mask switching	不能自动泛化到其他架构
E3 复现	同一机制在不同 fusion/decoder 架构重复成立	不能宣称所有 3D grounding 模型均如此

论文级机制主张至少需要 E2。D1 即使曲线很漂亮，也只能得到 candidate locus。

6. D0 - Behavioural Existence 可执行协议

6.1 目标

证明同一几何下的有效 query change 确实存在 point-level switching failure，并排除数据歧义、mask overlap、尺度、paraphrase noise 和评测阈值造成的伪象。

6.2 输入与冻结项

- LASO 官方 anno_train.pkl、anno_val.pkl、anno_test.pkl;
- objects_*.pkl 与 Affordance-Question.csv;
- 数据文件 hash、split、官方代码 commit;
- PointRefer 和 GEAL 官方 checkpoint; CMAT/LAS 仅在权重入口通过审计后加入;
- 统一 deterministic inference 配置。

6.3 D0-A: Pair inventory

- 1 按 split + shape_id 聚合标注。
- 2 枚举同 shape 不同 affordance 的 mask pair。
- 3 计算 foreground ratio、mask IoU、交并差区域大小、object class 和 affordance transition。
- 4 建立语义关系 taxonomy: distinct、overlap-valid、co-required、entailment/hierarchy、ambiguous。

- 5 只有 **distinct** 且差异区域足以稳定评测的 pair 进入主分析；IoU 仅作几何过滤，不替代语义判定。
- 6 双人盲审语义关系，保存分歧与最终裁决；不得在看模型结果后修改 pair。

必须输出：

- `artifacts/d0/pair_inventory.parquet`
- `artifacts/d0/pair_semantic_audit.csv`
- `artifacts/d0/excluded_pairs.csv`
- `artifacts/d0/dataset_summary.json`
- `artifacts/d0/data_hashes.json`

6.4 D0-B: Behaviour run manifest

每个合法 pair 运行：

- $(P, q_a) \rightarrow p_a$ 与 $(P, q_b) \rightarrow p_b$;
- 每个 query 的 paraphrase control;
- object-only、null、shuffle 和 wrong-object 仅作压力测试，不进入主要存在性判定；
- 同一 point order、归一化和随机状态，不改变几何输入。

主要行为量：

$$T(p; y_a, y_b) = S(p, y_b) - S(p, y_a)$$

其中 S 使用预注册的 soft-IoU 或 mask similarity。成功 switching 要求从 q_a 到 q_b 时， T 朝 y_b 方向变化；同时报告标准 aIoU/AUC/SIM/MAE，避免新指标脱离原任务。

统计单位是 shape，不是 pair。置信区间按 shape cluster bootstrap；同一 shape 的多个 pair 不得作为独立样本。

6.5 D0 裁决

SURVIVE：至少两个融合/解码设计不同的可复现模型，在语义有效 pair 上出现方向一致且超过 paraphrase/noise floor 的 switching failure，并且 overlap、scale、class 和 prompt surface form 不能解释主要效应。

WEAK：只在单模型、单类别或单一 transition 上成立，允许一次预注册的扩样或实现核查。

KILL：无法形成可靠 pair；强 baseline 均能正确 switching；或 failure 主要由数据歧义、区域重叠、尺度或语言噪声解释。

7. D1 - Representation Localization 可执行协议

7.1 Hook map

PointRefer 首轮记录：

- `forward_text()` 的 resized token representation;
- 三次 `gpb` 前后 point features;
- `fp1` 后 dense `up_sample`;
- transformer decoder 后 `t_feat`;
- sigmoid 前 point-wise logits 与最终 mask。

GEAL 首轮记录:

- `forward_text()` 输出;
- 三次 `GAFM_block` 前后 features;
- `fp1` 与 multi-level fusion 后 `fused_feat`;
- `text_decoded`;
- sigmoid 前 `affordance_map` 与最终 mask。

CMAT/LAS 首轮记录:

- `prompt_features` 与 `prompt_features_proj`;
- `point_group_features`、projected/upsampled point features;
- `unified_sequence`;
- co-attention 后 `fused_prompt_features` 与 `fused_point_features`;
- segmentation head 各层和 logits。

先为每个 hook 写 shape/dtype/device manifest; 只有语义一致的表示才能跨 query 比较。跨架构绝不直接比较 raw norm 大小。

7.2 每层三类读数

- 1 Global sensitivity: 有效 query pair 的 representation difference, 相对 paraphrase 与重复推理 noise floor 归一化。
- 2 Spatial relevance: 对每个点计算 $\Delta_l(i) = \|z_l^a(i) - z_l^b(i)\|$, 检查其是否集中在 `y_a XOR y_b`, 并与 common foreground、background 分开报告。
- 3 Readability: 用冻结表示训练简单 linear readout 判断 affordance 或 pair direction。Readout 只证明信息存在, 不证明原模型实际使用。

Cosine、CKA、RDM、probe accuracy 不设为唯一指标。必须检查结论是否对 metric choice 稳定, 以避免 activation-patching 文献已经指出的度量敏感性。

7.3 Candidate locus 判定

某区间只能在同时满足以下条件时进入 D2:

- 有效 query difference 在相邻阶段出现可重复的下降;
- paraphrase control 没有同样下降模式;
- pointwise spatial relevance 同步降低, 或 decoder readout 与 point signal 发生脱节;
- 模式跨 shape、affordance transition 和至少两个模型检查。

D1 输出: `layer_manifest.json`、逐样本 activation index、layerwise sensitivity 表、空间 delta map、candidate-locus report。Activation 原始文件使用 chunked tensor 格式并记录 checkpoint/hash, 避免只保存汇总图。

8. D2 - Causal Intervention 可执行协议

8.1 基本单位

对同一 (P, q_a, q_b, y_a, y_b) 建立 source run 与 target run。两条 query 都是有效输入，不称 “clean/corrupt”。干预只改变指定 activation 或计算路径，其他输入与权重保持不变。

8.2 Restoration

把 target-query run 的 candidate activation 或 query-dependent component patch 到 source-query run，测试输出是否朝 y_b 定向移动。先做整层/整路径 coarse patch 定位，再下钻到 token、point group、attention head 或 residual branch；不得从一开始大规模搜索所有组件。

主要效应：

$$\text{PatchEffect}_I = T(\text{patch}_I(a \leftarrow b); y_a, y_b) - T(p_a; y_a, y_b)$$

同时报告对 $y_a \text{ XOR } y_b$ 、共同前景和背景的局部效应，防止整体 logit shift 被误当作正确 routing。

8.3 Destruction

对原本 switching 正确的 pair，equalize、ablate 或交换 candidate query-dependent component，测试 targeted switching 是否受损。只有 restoration 有效但 destruction 无效时，最多说明该路径具有替代性，不足以声称必要机制。

8.4 Path-specific tests

按候选假设选择路径，而非统一套模板：

- H1: text encoder token/state interchange;
- H2: text-to-fusion attention output 与 residual branch patch;
- H3: global state 到 point/token 的 cross-attention、ungroup 或 feature-propagation 路径 patch;
- H4: 保持 Z_{point} ，干预 decoder query/dynamic kernel/readout path。

8.5 必要控制

- norm-matched random activation;
- paraphrase activation patch;
- 非候选层同强度 patch;
- point permutation 与区域外 point patch;
- geometry-path 等强度扰动;
- 原始任务分数、非目标区域和数值稳定性检查;
- 双方向 $a \leftarrow b$ 与 $b \leftarrow a$ 。

8.6 D2 裁决

MECHANISM-SURVIVE: restoration 与 destruction 形成方向一致的双向证据；行为变化集中在目标差异区域；random/paraphrase/non-candidate controls 不能复现效应；至少在一个第二架构中得到同类路径证据。

CORRELATE-ONLY: D1 有 sensitivity drop，但 restoration 不恢复或 destruction 不破坏 switching。该位置只能作为相关现象，继续查链路，禁止围绕它设计方法。

ARCHITECTURE-SPECIFIC: 只在一个模型成立。可形成模型诊断，但不能上升为领域机制。

9. 最小执行顺序与产物

工作包	内容	完成定义
P0 文献与代码冻结	Top-10 主张表、仓库 commit、可 hook 层级图	最近邻边界与 hook map 可审计
D0-A 数据审计	pair inventory、semantic audit、power/noise plan	决定数据能否回答问题
D0-B 行为诊断	预训练模型推理、cluster bootstrap、失败切片	决定现象是否存在
D1 层级定位	activation capture、spatial delta、candidate locus	只输出候选区间
D2 定点干预	coarse patch -> path/component patch -> controls	决定是否在机制证据
D3 方法	仅在 D2 survive 后启动	修改点由已验证机制唯一约束

首轮不训练新模型。优先用官方 checkpoint 完成 D0-D2 的推理与干预；instrumentation smoke test 只证明 hook 和输出正确，不能算实验结果。

10. 风险、反对意见与止损

最强反对意见

- 只是把 VLM activation patching 迁移到一个 3D 小模型和新任务。
- LASO 的有效 pair 太少或语义关系不清，导致行为 failure 不可信。
- Representation distance 的下降是归一化、token 数或 feature dimension 变化，不是信息丢失。
- Activation patch 产生 off-manifold state，mask 改变只是数值扰动。
- PointRefer、GEAL 和 CMAT 的 fusion 结构不同，没有共同的机制层级。
- Candidate locus 能影响输出，但不是唯一或必要路径，机制主张被 redundancy 推翻。
- 现象只发生在旧 baseline，强 encoder 已自然解决。

对应止损

- D0 不成立：停止本题。
- 最近邻已直接覆盖 dense 3D query-to-point causal localization：G1 KILL。
- D1 无稳定 candidate locus：不靠挑图继续故事。
- D2 无 targeted behavioural consequence：candidate locus 降为相关现象。
- Generic paired loss 完整恢复内部链路与行为：解释为 supervision deficiency，重新评估上限。
- 仅单模型成立：缩小为 architecture-specific diagnosis，不能宣称通用机制。
- 方法只提高 aloU、不恢复内部 sensitivity 与 switching：不能支持机制论文。

11. 当前立项判断

当前方向比“诊断 + 指标 + loss”更有科学上限，但也明显更难。它已经具备一个可证伪的机制发现流程，却尚未拥有任何已验证的 failure、candidate locus 或 causal mechanism。

当前唯一值得投入的工作是：

- 完成最近邻机制工作的全文主张级查重；
- 冻结并执行 D0/D1/D2 协议。

在 D2 以前，不投入方法命名、复杂模块设计、无人机仿真或论文包装。

参考文献与代码入口

- 1 Li et al. LASO: Language-guided Affordance Segmentation on 3D Object. CVPR 2024. [\[链接\]](#)
- 2 Lu et al. GEAL: Generalizable 3D Affordance Learning with Cross-Modal Consistency. CVPR 2025. [\[链接\]](#)
- 3 Li et al. Intermediate Connectors and Geometric Priors for Language-Guided Affordance Segmentation on Unseen Object Categories. ICCV 2025. [\[链接\]](#)
- 4 Huang et al. Unlocking 3D Affordance Segmentation with 2D Semantic Knowledge. CVPR 2026. [\[链接\]](#)
- 5 Sattigeri. GroundBench: A Factorized, Counterfactual Benchmark for Locating VLM Affordance Failures. arXiv 2026. [\[链接\]](#)
- 6 Palit et al. Towards Vision-Language Mechanistic Interpretability: A Causal Tracing Tool for BLIP. ICCV Workshop 2023. [\[链接\]](#)
- 7 Nikankin et al. Same Task, Different Circuits: Disentangling Modality-Specific Mechanisms in VLMs. NeurIPS 2025. [\[链接\]](#)
- 8 Lietzow et al. Vision-Default, Prior-Override: Causal Mechanisms of Perception-Knowledge Conflict in Vision-Language Models. arXiv 2026. [\[链接\]](#)
- 9 Liu et al. Dual-Pathway Circuits of Object Hallucination in Vision-Language Models. arXiv 2026. [\[链接\]](#)
- 10 Yan et al. Beyond Cross-Modal Alignment: Measuring and Leveraging Modality Gap in Vision-Language Models. Findings of ACL 2026. [\[链接\]](#)
- 11 Frank et al. Vision-and-Language or Vision-for-Language? On Cross-Modal Influence in Multimodal Transformers. EMNLP 2021. [\[链接\]](#)
- 12 Zhang and Nanda. Towards Best Practices of Activation Patching in Language Models: Metrics and Methods. ICLR 2024. [\[链接\]](#)
- 13 PointRefer official code. [\[链接\]](#)
- 14 GEAL official code. [\[链接\]](#)
- 15 CMAT/LAS official code. [\[链接\]](#)